Méthodes de catégorisation d’un intervalle [1 … 670] avec fréquences connues

Ce document décrit plusieurs méthodes permettant de découper l’intervalle des valeurs [1, 670] en quatre catégories : facile, moyen, difficile et très difficile, lorsque la fréquence f(i) de chaque valeur est connue.

1. Quartiles pondérés
On calcule la distribution cumulée pondérée. N = 670 le nombre de valeurs = somme des fréquences.
Les seuils correspondent aux positions Q1 = N/4,
Q2 = N/2, Q3 = 3N/4. Les catégories contiennent chacune 25% des données.

2. K-means pondéré 1D
On applique un clustering optimisé sur 1 dimension en pondérant chaque valeur i par f(i).
On obtient quatre clusters naturels.

3. Percentiles personnalisés
On choisit des seuils (ex. 20%, 30%, 30%, 20%) et on découpe l’histogramme cumulatif.

4. Optimisation métier
Les seuils peuvent être choisis pour minimiser une fonction (variance intra-groupe, séparation, etc.).

5. Découpage uniforme
Même taille d’intervalle : [1–167], [168–334], [335–501], [502–670].