Quantiles

1 Série statistique discrète

Une série, par exemple $\{3, 3, 5, 5, 5, 5, 6, 7, 7, 7, 7\}$, est la plupart du temps représentée par ses effectifs (équivalent histogramme) :$\{(3, 2), (5, 4), (6, 1), (7, 4)\}$ (on a 2 fois la valeur 3, 4 fois la valeur 5, etc.). Note importante : seule la série des effectifs est nécessaire car la série réelle s'en déduit sans jamais avoir besoin de la calculer.

2 Fonction quantile

Soit une série statistique discrète ordonnée $X = \{x_1, \cdots, x_n\}$ (ici pas de notion d'effectifs il peut y avoir des doublons). On définit une fonction de répartition empirique sur X :

$$F(x) = \#\{x_i \leq x\}/n$$

où $\#\{x_i \leq x\}$ est le nombre de valeurs de X qui sont inférieures ou égales x. Donc $F(x)$ représente la proportion de valeurs de X qui sont inférieures ou égales à x (avec $0 \leq F(x) \leq 1$). On note que $F(x)$ est définie pour tout $x \in \mathbb{R}$ où x, qui n'est pas nécessairement dans S, représente un seuil.

On définit la fonction quantile d'ordre p (avec $0 \leq p \leq 1$) ainsi :

$$Q(p) = min\{x_i \in X \mid F(x_i) \geq p\}.$$

$Q(p)$ retourne la plus petite valeur x_i de X tel qu'au moins une proportion p de valeurs de X sont inférieures ou égales à x_i.

Quand on veut partitionner X en 4 parties on utilise les quartiles définis par $Q_1 = Q(0.25)$, $Q_2 = Q(0.5)$ et $Q_3 = Q(0.75)$. Les parties sont les suivantes (en fonction des seuils) :

- $P_1 = \{x_i \in X |\ x_i \leq Q_1\}$,
- $P_2 = \{x_i \in X |\ Q_1 < x_i \leq Q_2\}$,
- $P_3 = \{x_i \in X |\ Q_2 < x_i \leq Q_3\}$,
- $P_4 = \{x_i \in X | x_i > Q_3\}$.

Quand on veut partitionner X en 5 parties on utilise les quintiles définis par $Q_1 = Q(0.2)$, $Q_2 = Q(0.4)$, $Q_3 = Q(0.6)$ et $Q_4 = Q(0.8)$.

Exemple 1
On considère la série ordonnée $X = \{1, 1, 2, 2, 2, 4, 4, 5, 5, 5\}$ contenant $n = 10$ valeurs. Les valeurs distinctes, leurs effectifs, les effectifs cumulés et les valeurs de la fonction de répartition sont résumés dans le tableau suivant :

Valeur x_i	*Effectif*	*Effectif cumulé*	$F(x_i)$
1	2	2	0.2
2	3	5	0.5
4	2	7	0.7
5	3	10	1.0

On a :

$$F(x) = \begin{cases} 0 & si\ x < 1, \\ 0.2 & si\ 1 \leq x < 2, \\ 0.5 & si\ 2 \leq x < 4, \\ 0.7 & si\ 4 \leq x < 5, \\ 1 & si\ x \geq 5. \end{cases}$$

Premier quartile $Q(0.25)$
On cherche le plus petit x_i *de* X *tel que* $F(x_i) \geq 0.25$.

$$F(1) = 0.2 < 0.25, \qquad F(2) = 0.5 \geq 0.25$$

Donc :

$$\boxed{Q(0.25) = 2}$$

$P_1 = \{x_i \in X |\ x_i \leq 2\} = \{1, 1, 2, 2, 2\}$

Médiane $Q(0.50)$
On cherche le plus petit x_i *de* X *tel que* $F(x_i) \geq 0.5$.

$$F(2) = 0.5 \geq 0.5$$

Donc :

$$\boxed{Q(0.5) = 2}$$

On remarque que le premier et le second quartile sont égaux : la plus petite proportion de valeurs de X *qui soit supérieure ou égale à 0.25 est aussi supérieure ou égale à 0.5.*
$P_2 = \{x_i \in X |\ 2 < x_i \leq 2\} = \emptyset$.

Troisième quartile $Q(0.75)$
On cherche le plus petit x_i *de* X *tel que* $F(x_i) \geq 0.75$.

$$F(4) = 0.7 < 0.75, \qquad F(5) = 1 \geq 0.75$$

Donc :

$$\boxed{Q(0.75) = 5}$$

$P_3 = \{x_i \in X |\ 2 < x_i \leq 5\} = \{4, 4, 5, 5, 5\}$

Enfin $P_4 = \{x_i \in X | x_i > 5\} = \emptyset$.

Remarque importante : du fait des égalités au sein d'une série les quantiles ne garantissent pas que les parties créées ont le même nombre d'éléments, et il peut y avoir des égalités entre quantiles.